

DeepLearning 入門

～『ゼロから作る Deep Learning』を読んで～

著：博ノ助

目次

1. 本書で用いる表現について	3
2. 多層パーセプトロン (MLP)	5
2.1. ニューロンの始まり	5
2.2. 多層パーセプトロン	6
2.3. 活性化関数	7
2.3.1. シグモイド関数	7
2.3.2. ReLU 関数	7
2.3.3. Softmax 関数	7
2.4. 行列表現と Affine 層	8
2.4.1. Affine 層	8
2.4.2. バッチ付き Affine 層	9
2.5. 行列表現での活性化関数の扱い	10
3. ニューラルネットワーク	11
3.1. 損失関数	11
3.1.1. 平均二乗誤差	11
3.1.2. クロスエントロピー誤差	11
3.2. 確率的勾配降下法 (SGD)	12
3.3. 誤差逆伝播法	12
3.3.1. 数値微分	12
3.3.2. 逆伝播法における連鎖律	13
3.3.3. 実数の逆伝播	14
3.3.4. Affine 層の逆伝播	15
3.3.5. ReLU 関数の逆伝播	17
3.3.6. Softmax 関数の逆伝播	17
3.3.7. クロスエントロピー誤差の逆伝播	19
3.3.8. Softmax 関数とクロスエントロピー誤差の組み合わせ	19
4. ニューラルネットワークの工夫	20
4.1. Optimizer	20
4.1.1. Momentum	20
4.1.2. RMSProp	20
4.1.3. Adam	20
4.1.4. AdamW	21
4.2. レイヤ	21
4.2.1. Batch Normalization 層	21
4.2.1.1. 順伝播	21
4.2.1.2. 逆伝播	22

4.2.2. Dropout 層	26
4.2.2.1. 順伝播	26
4.2.2.2. 逆伝播	27
4.3. ペナルティ項の追加	27
4.3.1. L1 正則化 (Lasso : Least Absolute Shrinkage and Selection Operator)	28
4.3.2. L2 正則化 (Ridge)	28
4.3.3. L1L2 正則化 (Elastic Net)	29
4.3.4. L2 正則化の問題点と AdamW	29
5. 畳み込みニューラルネットワーク	30
5.1. 畳み込みへの導入	30
5.1.1. 局所受容野	30
5.1.2. 重み共有	31
5.2. テンソルの導入	31
5.3. 畳み込み層	32
5.4. パディング	34
5.5. 畳み込みの高速化 (img2col + GM)	35

1. 本書で用いる表現について

x	X	スカラー
$\mathbf{x}$		行ベクトル (小文字・太文字) $1 \times N$ の行列と同一視する
x_j		ベクトル $\mathbf{x}$ の j 成分 (特に指定がない場合)
$\mathbf{1}_n$		要素数 n で成分が全て 1 の列ベクトル
	$\mathbf{X}$	行列 (大文字・太文字)
x_{ij}	$x_j^{(i)}$	行列 $\mathbf{X}$ の i, j 成分 (特に指定がない場合)
	$[\mathbf{X}]_{ij}$	行列 $\mathbf{X}$ の i, j 成分
	$\mathbf{X}^\top$	行列 $\mathbf{X}$ の転置
	$[\mathbf{X}]_{i*}$	行列 $\mathbf{X}$ の i 行を表す行ベクトル
	$[\mathbf{X}]_{*j}$	行列 $\mathbf{X}$ の j 列を表す列ベクトル
	$\mathcal{X}$	テンソル (大文字・太文字・カリグラフィー)
$x_{a_1 a_2 \dots a_n}$		テンソル $\mathcal{X}$ の $a_1, a_2, \dots, a_n$ 成分
$x_{a_1 a_2 \dots a_{n-1} *}$		$(x_{a_1 a_2 \dots 1}, x_{a_1 a_2 \dots 2}, \dots, x_{a_1 a_2 \dots a_n})$
	$\mathbf{x} \cdot \mathbf{y}$	ベクトル $\mathbf{x}$ とベクトル $\mathbf{y}$ の標準内積
	$\mathbf{x} \odot \mathbf{y}$	ベクトル $\mathbf{x}$ とベクトル $\mathbf{y}$ のアダマール積
	$\frac{\mathbf{x}}{\mathbf{y}}$	ベクトル $\mathbf{x}$ とベクトル $\mathbf{y}$ のアダマール除算
	$\mathbf{x}^{\circ n}$	ベクトル $\mathbf{x}$ 自身とのアダマール積を n 回行ったもの 各要素を n 乗したものと一致する
	$\mathbf{X} \cdot \mathbf{Y}$	行列 $\mathbf{X}$ と行列 $\mathbf{Y}$ のドット積
	$\mathbf{X} \odot \mathbf{Y}$	行列 $\mathbf{X}$ と行列 $\mathbf{Y}$ のアダマール積
	$\frac{\mathbf{X}}{\mathbf{Y}}$	行列 $\mathbf{X}$ と行列 $\mathbf{Y}$ のアダマール除算
	$\sqrt{\mathbf{X}}$	行列 $\mathbf{X}$ の各成分の平方根をとった行列 $[\sqrt{\mathbf{X}}]_{ij} = \sqrt{[\mathbf{X}]_{ij}}$
	$\frac{\partial}{\partial x}$	スカラー x に関する偏微分作用素
	$\frac{\partial}{\partial \mathbf{x}}$	$\left(\frac{\partial}{\partial x_1}, \frac{\partial}{\partial x_2}, \dots, \frac{\partial}{\partial x_n} \right)$
	$\frac{\partial}{\partial \mathbf{X}}$	$\left[\frac{\partial}{\partial \mathbf{X}} \right]_{ij} = \frac{\partial}{\partial x_{ij}}$
	$\mathbb{E}[f(x_1, x_2, \dots, x_n)]$	確率変数 $x_1, x_2, \dots, x_n$ に依存する関数 f の期待値
	$\mathbb{E}_p[f(x_1, x_2, \dots, x_n)]$	確率変数 p に依存する関数 f の期待値
	$\mathcal{N}(\mu, \sigma^2)$	平均 μ 、分散 σ^2 の正規分布
	$\text{Bi}(p)$	期待値 p のベルヌーイ分布

$$x \sim \mu$$


μ が確率分布を表すとき x はその分布に従うことを表す
しばしば、分布 μ から x をサンプリングすることを表す

2. 多層パーセプトロン (MLP)

この章では、DeepLearning の基礎である多層パーセプトロン (MLP) について学ぶ。最小単位ニューロンの構造を紹介し、その具体的な利用法と、限界について触れることでこの章で出現する様々な要素を導入するモチベーションを与える。


2.1. ニューロンの始まり

ニューロンは生物の神経細胞を模した情報処理の単位である。入力信号を受け取り、それに基づいて出力信号を生成する。



この際、入力の強さによって信号を出力するかどうかを決めることにしてみよう。これは生物的に行われていることであるが、これを数学的に表現するとステップ関数を用いることができる。


$$f_{\text{step}}(x) = \begin{cases} 1 & \text{if } x \geq 0 \\ 0 & \text{otherwise} \end{cases}$$



この関数では入力 x が 0 以上で発火することになる。しかしこれでは、0 か 1 しか伝播しないため、帰納的にすべてのニューロンが発火してしまう。そこで、ニューロン同士の結合の強さ w と、発火する閾値を調整する b というパラメータを導入することでニューロンの結合は意味を持つ。また、複数の入力に対してもその結合を考慮することができるように、ニューロンの出力は以下のように定義される。

$$\hat{f}_{\text{step}}(\mathbf{x}) =: f_{\text{step}}\left(\sum_i w_i x_i + b\right) = \begin{cases} 1 & \text{if } \sum_i w_i x_i \geq -b \\ 0 & \text{otherwise} \end{cases}$$


w_i は i 番目の入力 x_i に対する結合強度を表す。このようにしてニューロンは複数の入力を受け取り、それらの結合強度と閾値を考慮して出力を決定することができる。これをパーセプトロンという。このパーセプトロンによる実例を見てみよう。




$$z = f_{\text{step}}(x + y - 1.5) = \begin{cases} 1 & \text{if } x + y \geq 1.5 \\ 0 & \text{otherwise} \end{cases}$$

上のパーセプトロンは AND ゲートを模している。0 か 1 しかとらない入力 x と y に対して、ともに 1 のときのみ出力 z が 1 になり、それ以外のときは 0 になる。このことは上の式からわかるだろう。

次に OR ゲートを模したパーセプトロンを見てみよう。



上のパーセプトロンは OR ゲートを模している。0 か 1 しかとらない入力 x と y に対して、少なくとも片方が 1 のときのみ出力 z が 1 になり、それ以外のときは 0 になる。同じように入力 x に対して 0 ならば 1、1 ならば 0 を出力する NOT ゲートを模したパーセプトロンを実装できる。




2.2. 多層パーセプトロン

では、XOR ゲートはどうだろうか。XOR ゲートは 0 か 1 しかとらない入力 x と y に対して、片方が 1 のときのみ出力 z が 1 になり、それ以外のときは 0 になる関数である。しかし、XOR ゲートは上のようなパーセプトロンでは実装できない。右下のようなグラフを書いてみる。


二つの入力を x 軸 y 軸として、出力を色分けした。青色は 0、赤色は 1 を表している。ニューロンは

$$\hat{f}_{\text{step}}(w_1x + w_2y + b) = \begin{cases} 1 & \text{if } w_1x + w_2y \geq -b \\ 0 & \text{otherwise} \end{cases}$$

と表されるのであるが、これは直線 $w_1x + w_2y + b = 0$ を境界に xy 平面を分けることを意味する。



しかし、グラフを見ればわかるように直線 1 つで青と赤の点を分けることができない。これを、線形分離不可能という。XOR ゲートは線形分離不可能な関数である。したがって、XOR ゲートは 1 つのニューロンでは実装できない。しかし、XOR ゲートはいくつかの他の論理ゲートを組み合わせることで実装できることが知られている。



このように、XOR ゲートは OR ゲートと AND ゲートと NOT ゲートを組み合わせることで実装できる。複数のパーセプトロンをまるで層を重ねるように組み合わせることで、より複雑な関数を実装することができる。これを多層パーセプトロン (MLP) とよぶ。データの入力を受け付ける層を入力層、出力を表す層を出力層とよぶ。その間にある層を隠れ層とよぶ。入力層と出力層をみればデータの入出力の形だけはわかる。

2.3. 活性化関数


多層パーセプトロンは、複数のニューロンを組み合わせることでより複雑な関数を実装することができる。しかし、上のようなステップ関数 f_{step} では、出力が離散的で値の表現が乏しい。そのため、連続的な値を出力する関数を用いる。これら、ニューロンの出力を決定する関数を活性化関数とよぶ。

また、のちに多層パーセプトロンはいわゆる深層学習に使われるが、その際、微分が大きな役割を果たす。そのため、微分可能であるような関数が現在の活性化関数として用いられている。活性化関数の進化によって、ニューロンの「発火」という性質は薄れていった。一方で、パラメータ w, b は意味を変えつつもそのまま残っており、重み及びバイアスとよばれるようになった。

活性化関数には様々な種類があるが、ここでは代表的なものを紹介する。

2.3.1. シグモイド関数


$$f_{\text{sigmoid}}(x) = \frac{1}{1 + \exp(-x)}$$



シグモイド関数は、入力 x に対して 0 から 1 の値を出力する微分可能な関数である。これは、ニューロンの出力を確率として解釈することができる。ステップ関数と形が似ているため、ステップ関数の滑らかな近似としてよく用いられていた。しかし、入力の絶対値が十分大きい場合に、微分係数が 0 に近くなってしまったため、学習が進まなくなるといった問題¹がある。

2.3.2. ReLU 関数

$$f_{\text{ReLU}}(x) = \begin{cases} x & \text{if } x \geq 0 \\ 0 & \text{otherwise} \end{cases} = \max(0, x)$$



ReLU 関数は、入力 x に対して 0 以上の値を出力する微分可能な関数である。これは、入力が 0 以上のときはそのまま出力し、0 未満のときは 0 を出力する。シグモイド関数と比べて、勾配消失問題が起りにくいという利点があるため、現在ではデフォルトで用いられている。面白いことに、ReLU 関数はステップ関数を積分したものになっている。

2.3.3. Softmax 関数

$$f_{\text{softmax}}(x_i) = \frac{\exp(x_i)}{\sum_j \exp(x_j)}$$

¹これを勾配消失問題という。

Softmax 関数は、他の活性化関数とは異なり入力全体のベクトル $\mathbf{x}$ を用いる。 i 番目の要素 x_i に対して、 x_i の全体に占める割合に似たものを出力する。出力は 0 以上の値を持ち、全体の和は 1 になる。確率分布を表すために用いられる。

Softmax 関数を実装する際の注意点として、入力 x_i の値が大きいときに、 $\exp(x_i)$ がオーバーフローしてしまうことがある。これを防ぐために、全体の最大値を引いてから計算する。値が小さくても $\exp(x_i)$ は 0 に近づくだけなので問題ない。入力を定数分だけ引いても出力は変わらないので、この操作で出力は変化しない。


$$\begin{aligned}
 C &= \text{const.} \\
 \frac{\exp(x_i - C)}{\sum_j \exp(x_j - C)} &= \frac{e^{-C} \exp(x_i)}{\sum_j e^{-C} \exp(x_j)} \\
 &= \frac{e^{-C} \exp(x_i)}{e^{-C} \sum_j \exp(x_j)} \\
 &= \frac{\exp(x_i)}{\sum_j \exp(x_j)}
 \end{aligned}$$

2.4. 行列表現と Affine 層

ここでは、層構造をもつ多層パーセプトロンについて、効率的な計算をおこなうために行列計算に帰着できることを示す。

2.4.1. Affine 層

Affine 層は、入力 x に対して、重み W とバイアス b を用いて出力 y を計算する層である。活性化関数については一度目を瞑ることにする。最も基本的な形は以下の図で示されるようなものである。



いくつかのニューロンが並列に配置されており、これを層あるいはレイヤという。レイヤ内のニューロンの数を層の大きさとして、上図ではサイズ n のレイヤとサイズ m のレイヤが結合されている。また、上図では省略されているが、各入力には個別の重みとバイアスを持つ。

注意すべきなのが、各ニューロンの各入力について重みがあるという点である。例えば、右側レイヤの 1 番目のニューロンは左側レイヤの 1 番目のニューロンからの入力に対して重み $w_{1 \leftarrow 1}$ を持つ。加えて、右側レイヤの 2 番目のニューロンは左側レイヤの 1 番目のニューロンからの入力に先ほどとは異なる重み $w_{2 \leftarrow 1}$ を持つのである。ただし、バイアスはニューロンごとに 1 つしか持たない。

今現在、右側レイヤに注目する。左側レイヤの i 番目のニューロンの出力を x_i 、右側レイヤの j 番目がある x_i に対する重みを $w_{j \leftarrow i}$ と書くことにする。右側レイヤの j 番目のニューロンのバイアスを b_j 、出力を y_j とすると、以下のように表すことができる。

$$y_j = \sum_{1 \leq i \leq n} w_{j \leftarrow i} x_i + b_j$$

ここで、以下のような重み行列 $\mathbf{W}$ とバイアスベクトル $\mathbf{b}$ を定義する。

$$\mathbf{W} := \begin{pmatrix} w_{1 \leftarrow 1} & w_{2 \leftarrow 1} & \cdots & w_{m \leftarrow 1} \\ w_{1 \leftarrow 2} & w_{2 \leftarrow 2} & \cdots & w_{m \leftarrow 2} \\ \vdots & \vdots & \ddots & \vdots \\ w_{1 \leftarrow n} & w_{2 \leftarrow n} & \cdots & w_{m \leftarrow n} \end{pmatrix} \in \mathbb{M}^{n \times m}$$

$$\mathbf{b} := (b_1 \ b_2 \ \dots \ b_m)$$

$\mathbf{W}$ の i, j 成分 w_{ij} は $w_{j \leftarrow i}$ に一致している。この行列とベクトルを用いると、左側レイヤの出力 $\mathbf{x}$ に対して、右側レイヤの出力 $\mathbf{y}$ は以下のように表すことができる。

$$\mathbf{y} = \mathbf{x}\mathbf{W} + \mathbf{b}$$

簡単な行列計算で済むのである。

2.4.2. バッチ付き Affine 層

機械学習では複数のデータを同時に扱うことで計算を効率化することが一般的である。ここでいう、データとは $\mathbf{x}$ や $\mathbf{y}$ を 1 単位としている。時に、何億というデータを扱うこともあるため、コンピュータの性能が許す限り、一度に多くのデータを扱いたいのである。これをバッチ処理とよび、いくつかのデータをまとめたものをバッチとよぶ。また、一度に扱うデータの数をバッチサイズとよび、 $B \in \mathbb{N}$ と書くことにする。

Affine 層では、単に入出力をベクトルから行列に拡張するだけでバッチ処理を実現できる。次の $\mathbf{X}, \mathbf{Y}$ に入出力を改める。またバイアスも $\mathbf{B}$ に改める。ただし、バッチ内の i 番目のデータを $\mathbf{x}_i, \mathbf{y}_i$ とする。

$$\begin{aligned} \mathbf{X} &:= (\mathbf{x}_1 \ \mathbf{x}_2 \ \dots \ \mathbf{x}_B)^\top \in \mathbb{M}^{B \times n} \\ \mathbf{Y} &:= (\mathbf{y}_1 \ \mathbf{y}_2 \ \dots \ \mathbf{y}_B)^\top \in \mathbb{M}^{B \times m} \\ \mathbf{B} &:= (\mathbf{b} \ \mathbf{b} \ \dots \ \mathbf{b})^\top \in \mathbb{M}^{B \times m} \\ &= \mathbf{1}_B \cdot \mathbf{b} \end{aligned}$$

$\mathbf{1}_n$ は成分がすべて 1 で n 次元列ベクトルである。このベクトルと、任意の行ベクトル $\mathbf{b}$ のドット積は、 $\mathbf{b}$ の成分を n 行分だけコピーした行列になる。これをベクトルのブロードキャストとよぶ。さて、これは先ほどと同様に行列の積で計算できる。

$$\mathbf{Y} = \mathbf{X} \cdot \mathbf{W} + \mathbf{B}$$

これは以下のように正当化される。

$$\begin{aligned} \mathbf{X} \cdot \mathbf{W} + \mathbf{B} &= (\mathbf{x}_1 \ \mathbf{x}_2 \ \dots \ \mathbf{x}_B)^\top \cdot \mathbf{W} + \mathbf{B} \\ &= (\mathbf{x}_1 \cdot \mathbf{W} \ \mathbf{x}_2 \cdot \mathbf{W} \ \dots \ \mathbf{x}_B \cdot \mathbf{W})^\top + (\mathbf{b} \ \mathbf{b} \ \dots \ \mathbf{b})^\top \\ &= (\mathbf{x}_1 \cdot \mathbf{W} + \mathbf{b} \ \mathbf{x}_2 \cdot \mathbf{W} + \mathbf{b} \ \dots \ \mathbf{x}_B \cdot \mathbf{W} + \mathbf{b})^\top \\ &= (\mathbf{y}_1 \ \mathbf{y}_2 \ \dots \ \mathbf{y}_B)^\top \\ &= \mathbf{Y} \end{aligned}$$

2.5. 行列表現での活性化関数の扱い

活性化関数は Affine 層とは別と考えることができる。実際の深層学習フレームワークでは一緒に利用できるように実装されているが、ここでは別々に考えることにする。ReLU やシグモイドなどの関数は、行列の個々の要素に対して適用すれば良い。

$$\begin{aligned} [\mathbf{Y}]_{ij} &= f_{\text{ReLU}}([\mathbf{X}]_{ij}) \\ [\mathbf{Y}]_{ij} &= f_{\text{sigmoid}}([\mathbf{X}]_{ij}) \end{aligned}$$

Softmax 関数などのデータ全体を用いる関数は、バッチ内のデータごとに適用すれば良い。行列表現では行ごとということになる。

$$[\mathbf{Y}]_{ij} = \frac{\exp([\mathbf{X}]_{ij})}{\sum_k \exp([\mathbf{X}]_{ik})}$$

3. ニューラルネットワーク

多層パーセプトロンを実装するだけでは、意図した出力を得ることはできない。適正なパラメータを与えなければならない。しかし、人間が正確なパラメータを与えることはおよその場合、不可能である。このパラメータを自動的に調整する方法が必要である。深層学習とはつまるところ、パラメータを自動的に調整することである。

多層パーセプトロンに与えるデータを $\mathbf{x}$ 、それを与えた場合に出力されるべきデータを $\mathbf{t}$ 、実際に出力されたデータを $\mathbf{y}$ とする。 $\mathbf{t}$ と $\mathbf{y}$ は大きさ C のベクトルとする。

3.1. 損失関数

損失関数 $\mathcal{L}$ は、実際に出力されるデータ $\mathbf{t}$ と与えられたデータ $\mathbf{y}$ の差を表す関数である。これは、パラメータを調整するための指標となる。多層パーセプトロンは数学的には $\mathbf{x}$ だけでなく、用いるパラメータ $\mathbf{p}$ すべてを引数にとる多変数関数とみなせる。なので、その出力を引数に持つ、損失関数もそれらを引数に持つ多変数関数とみなせる。ここで、 $\mathbf{t}$ は決められた定数とみなす。

$$\mathcal{L} : \mathbb{R}^{|\mathbf{x}|} \times \mathbb{R}^{|\mathbf{p}|} \rightarrow \mathbb{R}$$

いくつかの損失関数があるが、ここでは代表的なものを紹介する。

3.1.1. 平均二乗誤差

平均二乗誤差は、 $\mathbf{y}$ と $\mathbf{t}$ の個々の差を二乗して足し合せて平均をとったものである。これは、出力の値が連続的な場合に用いられる。

$$\mathcal{L}_{\text{MSE}} = \frac{1}{C} \|\mathbf{y} - \mathbf{t}\|^2$$


3.1.2. クロスエントロピー誤差

クロスエントロピー誤差は、 $\mathbf{y}$ と $\mathbf{t}$ を確率分布とみなして、その確率分布の誤差を表すものである。分類問題において使われることが多い。Softmax 関数と組み合わせて用いることが多い。

$$\mathcal{L}_{\text{CrossEntropy}} = - \sum_{1 \leq j \leq C} t_j \log(y_j)$$

3.2. 確率的勾配降下法 (SGD)

損失を最小化することが、深層学習の目標である。あるパラメータ p を更新することを考えよう。損失関数 $\mathcal{L}$ は先述した通り、 p を引数に持つ。 p についての $\mathcal{L}$ のグラフを書くと以下ようになる。



実際は p に対する $\mathcal{L}$ の形はわからない。しかし、 p での傾きを知ることができる。これは後述する。 p_1 のように傾きが負のときは、 p を増やすことで損失が減る。 p_2 のように傾きが正のときは、 p を減らすことで損失が減る。したがって、 p を更新する際には、傾きに応じて p を増減させれば良い。これを勾配降下法という。つまり、 p の更新は以下のように行う。

$$p \leftarrow p - \eta \frac{\partial \mathcal{L}}{\partial p}$$

ここで、 η は学習率とよばれる定数である。これは、 p の更新幅を決めるものである。 η が大きすぎると、最適なパラメータを通り過ぎてしまうことがある。逆に小さすぎると、最適なパラメータにたどり着くまでに時間がかかる。この更新方法を確率的勾配降下法 (SGD) とよぶ。

現在、パラメータの更新には SGD に様々な工夫を加えたものが用いられている。しかし、偏微分を考えるという部分は変わらない。

3.3. 誤差逆伝播法

さて、SGD を用いるためには、 $\mathcal{L}$ の偏微分を計算する必要がある。 $\mathcal{L}$ は多層パーセプトロンの出力を引数に持つ多変数関数である。したがって、 $\mathcal{L}$ の偏微分は連鎖律を用いて計算できる。

3.3.1. 数値微分

連鎖律を用いる以外には、数値微分を用いる方法がある。本書では、連鎖律を用いることを前提としているので、詳しくは述べないが紹介だけしておく。数値微分は、 $\mathcal{L}$ の入力を少しだけ変えて、出力の変化をみることで偏微分を求める方法である。 p についての偏微分は以下のように表される。そもそも、偏微分の定義は以下のようなものであった。

$$\frac{\partial \mathcal{L}}{\partial p} = \lim_{\delta \rightarrow 0} \frac{\mathcal{L}(p + \delta) - \mathcal{L}(p)}{\delta}$$

これを簡単に求められない、つまり四則演算を用いて計算することができないのは δ を 0 に近づけるためである。そこで、 δ を極めて小さな値にし、

$$\frac{\mathcal{L}(p + \delta) - \mathcal{L}(p)}{\delta}$$


を計算することで、近似的に偏微分を求めることができる。このように、 δ を用いて偏微分を近似的に求める方法を数値微分とよぶ。上の式は、 δ が正なら前方差分、 δ が負なら後方差分とよばれる。しかし、求めたいのは p における偏微分であるのでこれらの計算は誤差が大きい。したがって、以下のように p を中心にした差分を計算することが多い。これを中心差分とよぶ。中心差分は前方差分や後方差分よりも精度がいいことは解析的に示すことができる。

$$\frac{\mathcal{L}(p + \delta) - \mathcal{L}(p - \delta)}{2\delta}$$

すべてのパラメータに対して、 δ を用いて偏微分を近似的に求めることができればいいが、パラメータの数は膨大であるため、計算量が膨大になってしまう。また、より精度のいい5点公式や7点公式などもある。

3.3.2. 逆伝播法における連鎖律

改めて、今の目的は $\mathcal{L}$ のあるパラメータ p に関する偏微分を求めることである。以下のような計算を考えてみる。



$w^{(1)}$ および $w^{(2)}$ は学習可能なパラメータで、 $y^{(1)}$ および $y^{(2)}$ は $w^{(1)}, x^{(1)}$ および $w^{(2)}, x^{(2)}$ で何かしらの計算が行われる。 $y^{(1)}$ は $x^{(2)}$ と同じである。 $\mathcal{L}$ は $y^{(2)}$ と t を用いて計算される。

たとえば、 $w^{(2)}$ による偏微分を求めることを考えてみよう。 $w^{(2)}$ は $y^{(2)}$ に影響を与えており（これを寄与しているという）、 $y^{(2)}$ は $\mathcal{L}$ に寄与している。したがって、 $w^{(2)}$ の偏微分は連鎖律をもって以下のように表される。

$$\frac{\partial \mathcal{L}}{\partial w^{(2)}} = \frac{\partial \mathcal{L}}{\partial y^{(2)}} \frac{\partial y^{(2)}}{\partial w^{(2)}}$$

ここで、 $\mathcal{L}$ は $y^{(2)}$ と t を用いて計算されているので、当然 $y^{(2)}$ に関する偏微分 $\frac{\partial \mathcal{L}}{\partial y^{(2)}}$ は $y^{(2)}$ と t を用いて計算可能であり、既知である。同様に、 $y^{(2)}$ は $w^{(2)}$ と $x^{(2)}$ を用いて計算されているので、 $w^{(2)}$ に関する偏微分 $\frac{\partial y^{(2)}}{\partial w^{(2)}}$ も既知である。したがって、 $w^{(2)}$ に関する偏微分 $\frac{\partial \mathcal{L}}{\partial w^{(2)}}$ は求めることができる。

次に、 $w^{(1)}$ による偏微分を求める。 $w^{(1)}$ は $y^{(1)}$ に寄与しており、 $y^{(1)}$ は $x^{(2)}$ と同一である。 $x^{(2)}$ は $y^{(2)}$ に寄与しており、 $y^{(2)}$ は $\mathcal{L}$ に寄与している。したがって、 $w^{(1)}$ の偏微分は連鎖律をもって以下のように表される。

$$\frac{\partial \mathcal{L}}{\partial w^{(1)}} = \frac{\partial \mathcal{L}}{\partial y^{(2)}} \frac{\partial y^{(2)}}{\partial x^{(2)}} \frac{\partial y^{(1)}}{\partial w^{(1)}}$$

これらはすべて既知であるので、 $w^{(1)}$ に関する偏微分 $\frac{\partial \mathcal{L}}{\partial w^{(1)}}$ は求めることができる。ここで重要なのは、学習可能なパラメータではない $x^{(2)}$ に関する偏微分を用意しておく必要があるのである。それ自体は学習に使うわけではないが、より上位の層に伝播するために必要である。これを逆伝播とよぶ。

つまり、各層ではより下位（順伝播では次に値する層）からの偏微分係数を受け取り、連鎖律を用いて学習可能なパラメータの勾配を求め、上位の層に伝播するために順伝播では入力に値するものの偏微分係数を求めるように実装すれば、繰り返し行うことですべてのパラメータに関する偏微分を求めることができる。では、各層の逆伝播の計算を順伝播の計算を元に求めることを次に考える。

3.3.3. 実数の逆伝播

行列で逆伝播を考える前に、実数の逆伝播法を考える。例えばある実数を返す関数 $\mathcal{L}^2$ に関してある出力 y による偏微分係数 $\frac{\partial \mathcal{L}}{\partial y}$ が既知であるとする。そして入力 x に関して、

$$y = wx + b$$

が成立するとする。 w, b は更新対象のパラメータである。勾配降下法を用いるためにはこれらのパラメータに関する偏微分係数が必要である。そのためにまず、 y の偏微分を求める。

$$\frac{\partial y}{\partial x} = w \quad \frac{\partial y}{\partial w} = x \quad \frac{\partial y}{\partial b} = 1$$

次にこれらの関係をまとめると、

$$\begin{aligned} x &\mapsto y \mapsto \mathcal{L}(y) \\ w &\mapsto y \mapsto \mathcal{L}(y) \\ b &\mapsto y \mapsto \mathcal{L}(y) \end{aligned}$$

であるので、連鎖律を用いて以下のように表すことができる。

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x} &= \frac{\partial \mathcal{L}}{\partial y} \frac{\partial y}{\partial x} = w \frac{\partial \mathcal{L}}{\partial y} \\ \frac{\partial \mathcal{L}}{\partial w} &= \frac{\partial \mathcal{L}}{\partial y} \frac{\partial y}{\partial w} = x \frac{\partial \mathcal{L}}{\partial y} \\ \frac{\partial \mathcal{L}}{\partial b} &= \frac{\partial \mathcal{L}}{\partial y} \frac{\partial y}{\partial b} = \frac{\partial \mathcal{L}}{\partial y} \end{aligned}$$

²表現からも分かる通り、損失関数を念頭に置いている。

ここで、 $\frac{\partial \mathcal{L}}{\partial y}$ は既知であるので、入力とパラメータに関する偏微分係数を求めることができた。 $\frac{\partial \mathcal{L}}{\partial x}$ はこの前の層にとっては既知とされた $\frac{\partial \mathcal{L}}{\partial y}$ に対応する。

3.3.4. Affine 層の逆伝播

ある行列 $\mathbf{X} \in \mathbb{M}^{n \times m}$ について $\frac{\partial}{\partial \mathbf{X}}$ を次のように定義する。

$$\frac{\partial}{\partial \mathbf{X}} := \begin{pmatrix} \frac{\partial}{\partial x_{11}} & \frac{\partial}{\partial x_{12}} & \cdots & \frac{\partial}{\partial x_{1m}} \\ \frac{\partial}{\partial x_{21}} & \frac{\partial}{\partial x_{22}} & \cdots & \frac{\partial}{\partial x_{2m}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial}{\partial x_{n1}} & \frac{\partial}{\partial x_{n2}} & \cdots & \frac{\partial}{\partial x_{nm}} \end{pmatrix}$$

$\frac{\partial}{\partial \mathbf{X}}$ 自身も形式上は $n \times m$ の行列であり、ドット積は形式的に行える。左側から行われた場合は、例えば $\frac{\partial}{\partial x_{11}} y$ のように書くことができるが、 y を x_{11} で偏微分するという意味になる。

これを踏まえて、バッチ付き Affine 層の逆伝播を考える。Affine 層の出力 $\mathbf{Y}$ についての実数関数 $\mathcal{L}$ の偏微分 $\frac{\partial \mathcal{L}}{\partial \mathbf{Y}}$ は既知であるとする。なお、要素を書き下すと以下のようになることに注意されたい。

$$\frac{\partial \mathcal{L}}{\partial \mathbf{Y}} := \begin{pmatrix} \frac{\partial \mathcal{L}}{\partial y_{11}} & \frac{\partial \mathcal{L}}{\partial y_{12}} & \cdots & \frac{\partial \mathcal{L}}{\partial y_{1m}} \\ \frac{\partial \mathcal{L}}{\partial y_{21}} & \frac{\partial \mathcal{L}}{\partial y_{22}} & \cdots & \frac{\partial \mathcal{L}}{\partial y_{2m}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial \mathcal{L}}{\partial y_{n1}} & \frac{\partial \mathcal{L}}{\partial y_{n2}} & \cdots & \frac{\partial \mathcal{L}}{\partial y_{nm}} \end{pmatrix}$$

Affine 層は以下のような演算を行うことは既に述べた通りである。

$$\mathbf{Y} = \mathbf{X} \cdot \mathbf{W} + \mathbf{B}$$

y_{ij} について以下のように書き下せる。

$$y_{ij} = \sum_{1 \leq \alpha \leq n} x_{i\alpha} w_{\alpha j} + b_j$$

つぎに、両辺を w_{pq} と x_{pq} で偏微分すると、

$$\frac{\partial y_{ij}}{\partial w_{pq}} = \begin{cases} x_{ip} & \text{if } j = q \\ 0 & \text{otherwise} \end{cases}$$

$$\frac{\partial y_{ij}}{\partial x_{pq}} = \begin{cases} w_{qj} & \text{if } i = p \\ 0 & \text{otherwise} \end{cases}$$

となる. X の行と W の列は固定されているので、式にそれらが出現しないと偏微分係数は 0 になる。そして、 $\mathcal{L}$ がどのように w_{pq} に依存しているかを示すと、

$$w_{pq} \mapsto y_{ij} \ (1 \leq \forall i \leq n, 1 \leq \forall j \leq m) \mapsto \mathcal{L}$$

となっているので、

$$\begin{aligned} \left[\frac{\partial \mathcal{L}}{\partial \mathbf{W}} \right]_{pq} &= \frac{\partial \mathcal{L}}{\partial w_{pq}} = \sum_{1 \leq i \leq n} \sum_{1 \leq j \leq m} \frac{\partial \mathcal{L}}{\partial y_{ij}} \frac{\partial y_{ij}}{\partial w_{pq}} \\ &= \sum_{1 \leq i \leq n} \frac{\partial \mathcal{L}}{\partial y_{iq}} x_{ip} \\ &= \sum_{1 \leq i \leq n} \left[\frac{\partial \mathcal{L}}{\partial \mathbf{Y}} \right]_{iq} [\mathbf{X}]_{ip} \\ &= \sum_{1 \leq i \leq n} [\mathbf{X}^\top]_{pi} \left[\frac{\partial \mathcal{L}}{\partial \mathbf{Y}} \right]_{iq} \end{aligned}$$

が成立する。これはまさに、行列のドット積の定義であるので

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}} = \mathbf{X}^\top \cdot \frac{\partial \mathcal{L}}{\partial \mathbf{Y}}$$

が成立する。同様に

$$\frac{\partial \mathcal{L}}{\partial \mathbf{X}} = \frac{\partial \mathcal{L}}{\partial \mathbf{Y}} \cdot \mathbf{W}^\top$$

も成立する。 $\mathbf{X}, \mathbf{W}, \frac{\partial \mathcal{L}}{\partial \mathbf{Y}}$ は既知であるので、重みの偏微分係数を求めることができた。さて、バイアスについては、以下のような依存関係がある。

$$b_j \mapsto y_{ij} \ (1 \leq \forall i \leq n) \mapsto \mathcal{L}$$

したがって、 b_j について偏微分すると

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial b_j} &= \sum_{1 \leq i \leq n} \frac{\partial \mathcal{L}}{\partial y_{ij}} \frac{\partial y_{ij}}{\partial b_j} \\ &= \sum_{1 \leq i \leq n} \frac{\partial \mathcal{L}}{\partial y_{ij}} \end{aligned}$$

となる。 b_j は y_{ij} に依存しているので、 j 番目の列の和をとることになる。したがって、逆伝播は以下のように表せる。

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}} = \sum_{1 \leq i \leq n} \left[\frac{\partial \mathcal{L}}{\partial \mathbf{Y}} \right]_{i,*}$$

3.3.5. ReLU 関数の逆伝播

ReLU 関数は非常に簡単に逆伝播できる。ReLU 関数は以下のように定義されていた。

$$y_{ij} = \begin{cases} x_{ij} & \text{if } x_{ij} \geq 0 \\ 0 & \text{otherwise} \end{cases}$$

これを x_{pq} について偏微分すれば

$$\frac{\partial y_{ij}}{\partial x_{pq}} = \begin{cases} 1 & \text{if } i = p \wedge j = q \wedge x_{ij} \geq 0 \\ 0 & \text{otherwise} \end{cases}$$

となる。よって、

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x_{pq}} &= \sum_{1 \leq i \leq n} \sum_{1 \leq j \leq m} \frac{\partial \mathcal{L}}{\partial y_{ij}} \frac{\partial y_{ij}}{\partial x_{pq}} \\ &= \begin{cases} 1 & \text{if } x_{pq} \geq 0 \\ 0 & \text{otherwise} \end{cases} \end{aligned}$$

となる。ReLU 関数自体が、行列の各要素ごとに適応されるため、その逆伝播も行列の各要素ごとに適応される。したがって、ReLU 関数の逆伝播は行列の計算を伴わず非常に簡単である。

3.3.6. Softmax 関数の逆伝播

Softmax 関数は、行列の各行ごとに適応される。したがって、Softmax 関数の逆伝播も行列の各行ごとに考える。この節に限り、入力を $\mathbf{x}$ 、出力を $\mathbf{y}$ とする。ともに大きさ C である。すると、Softmax 関数は以下のように定義されていた。

$$y_j = \frac{\exp(x_j)}{\sum_k \exp(x_k)}$$

右辺の分母を S とすると、 y_j を x_q で偏微分すると

$$\begin{aligned}
\frac{\partial y_j}{\partial x_q} &= \begin{cases} \frac{\exp(x_j)S - \exp(x_j)\{0 + \exp(x_j)\}}{S^2} & \text{if } j = q \\ -\frac{\exp(x_j)\{0 + \exp(x_j)\}}{S^2} & \text{otherwise} \end{cases} \\
&= \begin{cases} \frac{\exp(x_j)}{S} - \frac{\exp(x_j)^2}{S^2} & \text{if } j = q \\ -\frac{\exp(x_j)^2}{S^2} & \text{otherwise} \end{cases} \\
&= \begin{cases} y_j - y_j^2 & \text{if } j = q \\ -y_j y_q & \text{otherwise} \end{cases} = y_j(\delta_{jq} - y_q)
\end{aligned}$$

となる。ここで、 δ_{jq} は Kronecker のデルタである。 $j = q$ のときは 1、それ以外は 0 である。依存関係は以下のように表せる。

$$x_q \mapsto y_j \ (1 \leq \forall j \leq C) \mapsto \mathcal{L}$$

連鎖律を用いれば以下のように求められる。

$$\begin{aligned}
\frac{\partial \mathcal{L}}{\partial x_q} &= \sum_{1 \leq j \leq C} \frac{\partial \mathcal{L}}{\partial y_j} \frac{\partial y_j}{\partial x_q} \\
&= \sum_{\substack{1 \leq j \leq C \\ j \neq q}} \frac{\partial \mathcal{L}}{\partial y_j} (-y_j y_q) + \frac{\partial \mathcal{L}}{\partial y_q} (y_q - y_q^2) \\
&= \sum_{1 \leq j \leq C} \frac{\partial \mathcal{L}}{\partial y_j} (-y_j y_q) + \frac{\partial \mathcal{L}}{\partial y_q} y_q \\
&= \sum_{1 \leq j \leq C} \left[\frac{\partial \mathcal{L}}{\partial \mathbf{y}} \right]_j \left[\begin{pmatrix} y_1 & & & \\ & y_2 & & \\ & & \ddots & \\ & & & y_C \end{pmatrix} \right]_{jq} - \sum_{1 \leq j \leq C} \left[\frac{\partial \mathcal{L}}{\partial \mathbf{y}} \right]_j \left[\begin{pmatrix} y_1 y_1 & y_1 y_2 & \cdots & y_1 y_C \\ y_2 y_1 & y_2 y_2 & \cdots & y_2 y_C \\ \vdots & \vdots & \ddots & \vdots \\ y_C y_1 & y_C y_2 & \cdots & y_C y_C \end{pmatrix} \right]_{jq}
\end{aligned}$$

やや強引な式変形を行うと、簡単に求めることができる行列を用いることができる。以上から、

$$\begin{aligned}
\frac{\partial \mathcal{L}}{\partial \mathbf{x}} &= \frac{\partial \mathcal{L}}{\partial \mathbf{y}} \cdot \left\{ \begin{pmatrix} y_1 & & & \\ & y_2 & & \\ & & \ddots & \\ & & & y_C \end{pmatrix} - \begin{pmatrix} y_1 y_1 & y_1 y_2 & \cdots & y_1 y_C \\ y_2 y_1 & y_2 y_2 & \cdots & y_2 y_C \\ \vdots & \vdots & \ddots & \vdots \\ y_C y_1 & y_C y_2 & \cdots & y_C y_C \end{pmatrix} \right\} \\
&= \frac{\partial \mathcal{L}}{\partial \mathbf{y}} \cdot \{\text{diag}(\mathbf{y}) - \mathbf{y}^\top \cdot \mathbf{y}\}
\end{aligned}$$

ここで、 $\text{diag}(\mathbf{y})$ は $\mathbf{y}$ の対角行列を表す。numpy などのライブラリには `diag` が実装されていることが多い。

3.3.7. クロスエントロピー誤差の逆伝播

レイヤと同じように損失関数にも逆伝播が必要である。逆伝播の開始位置ともいえるだろう。クロスエントロピー誤差は以下のように定義されていた。ただし、モデルの出力を $\mathbf{x}$ 、教師データを $\mathbf{t}$ とする。

$$\mathcal{L} = -\frac{1}{C} \sum_{1 \leq j \leq C} t_j \log(x_j)$$

Softmax 関数と同様に行ごとに適応される。逆伝播はすぐに求めることができる。

$$\frac{\partial \mathcal{L}}{\partial y_j} = -\frac{1}{C} \frac{t_j}{x_j}$$

3.3.8. Softmax 関数とクロスエントロピー誤差の組み合わせ

Softmax 関数とクロスエントロピー誤差は、組み合わせて用いることが多い。というのも、Softmax 関数は確率分布を表し、クロスエントロピー誤差は確率分布の誤差を表すからである。Softmax 関数とクロスエントロピー誤差を組み合わせて逆伝播を求めてみる。ただし、Softmax 関数への入力を $\mathbf{x}$ 、出力を $\mathbf{y}$ クロスエントロピー誤差の教師データを $\mathbf{t}$ とする。

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x_q} &= \sum_{1 \leq j \leq C} \frac{\partial \mathcal{L}}{\partial y_j} \frac{\partial y_j}{\partial x_q} \\ &= \sum_{1 \leq j \leq C} \frac{\partial \mathcal{L}}{\partial y_j} (-y_j y_q) + \frac{\partial \mathcal{L}}{\partial y_q} y_q \\ &= \sum_{1 \leq j \leq C} \left(-\frac{1}{C} \frac{t_j}{y_j} \right) (-y_j y_q) + \left(-\frac{1}{C} \frac{t_q}{y_q} \right) y_q \\ &= \frac{y_q}{C} \left(\sum_{1 \leq j \leq C} t_j - t_q \right) \\ &= \frac{y_q - t_q}{C} \end{aligned}$$

ここで、 t_j はクロスエントロピー誤差の教師データである。 t_j は正規化されているので、 $\sum_{1 \leq j \leq C} t_j = 1$ である。このように、Softmax 関数とクロスエントロピー誤差を組み合わせることで、非常に簡単に逆伝播を求めることができる。加えて、Softmax 関数もクロスエントロピー誤差も行列計算不可能にも関わらず、この逆伝播はバッチ付きの行列計算で表現できる。

$$\frac{\partial \mathcal{L}}{\partial \mathbf{X}} = \frac{1}{C} (\mathbf{Y} - \mathbf{T})$$

4. ニューラルネットワークの工夫

前章までで、ニューラルネットワークの基本的な部分を学んだ。ここからは、ニューラルネットワークをより効率的に学習させるための工夫を紹介する。

4.1. Optimizer

Optimizer は、パラメータを更新するためのアルゴリズムである。SGD は Optimizer の一つである。ここでは、SGD にさまざまな工夫を加えた Optimizer を紹介する。この章ではあるパラメータ $\mathbb{P}$ を更新することを考える。

4.1.1. Momentum

Momentum は、SGD の更新に過去の更新を引き継いだ慣性のようなものを加えたものである。前回までの更新を M に保存し、新たな更新では勾配と M の両方を用いる。

$$\begin{aligned} M &\leftarrow \alpha M - \eta \frac{\partial \mathcal{L}}{\partial \mathbf{P}} \\ \mathbf{P} &\leftarrow \mathbf{P} + M \end{aligned}$$

4.1.2. RMSProp

RMSProp は、SGD の更新に対して学習率を調整する機能を付け加えたものである。更新分が一定だと、最小に近づくにつれ、更新幅が必要な幅より大きくなってしまいう問題を解決するため、更新幅の分だけ学習率を割り引く。更新幅は指数移動平均を用いて計算し、ある程度過去の更新幅を引き継ぐ。

$$\begin{aligned} \mathbf{G} &\leftarrow \beta \mathbf{G} + (1 - \beta) \frac{\partial \mathcal{L}}{\partial \mathbf{P}} \odot \frac{\partial \mathcal{L}}{\partial \mathbf{P}} \\ \mathbf{P} &\leftarrow \mathbf{P} - \frac{\eta}{\sqrt{\mathbf{G}}} \frac{\partial \mathcal{L}}{\partial \mathbf{P}} \end{aligned}$$

パラメータごとに学習率を調整するために、アダマール積とアダマール除算を用いている。

4.1.3. Adam

Adam は、Momentum と RMSProp を組み合わせたものである。

$$\begin{aligned} \mathbf{M} &\leftarrow \beta_1 \mathbf{M} + (1 - \beta_1) \frac{\partial \mathcal{L}}{\partial \mathbf{P}} \\ \mathbf{G} &\leftarrow \beta_2 \mathbf{G} + (1 - \beta_2) \frac{\partial \mathcal{L}}{\partial \mathbf{P}} \odot \frac{\partial \mathcal{L}}{\partial \mathbf{P}} \\ \widehat{\mathbf{M}} &= \frac{\mathbf{M}}{1 - \beta_1^{t+1}} \quad \widehat{\mathbf{G}} = \frac{\mathbf{G}}{1 - \beta_2^{t+1}} \\ \mathbf{P} &\leftarrow \mathbf{P} - \frac{\eta}{\sqrt{\widehat{\mathbf{G}}}} \widehat{\mathbf{M}} \\ t &\leftarrow t + 1 \end{aligned}$$

4.1.4. AdamW

AdamW は、Adam に L2 正則化を加えたものである。L2 正則化と AdamW の構造についてはペナルティ項の追加にて後述する。

4.2. レイヤ

Affine 層や活性化関数層以外の、レイヤを追加することで学習を加速あるいは、精度を上げることができる。ここでは、代表的なレイヤを紹介する。

4.2.1. Batch Normalization 層

4.2.1.1. 順伝播

学習時はバッチを用いて複数のデータを同時に学習する。この際、バッチ内のデータに偏りが存在する場合があります、学習が進まないことがある。また、途中の層の出力が極端になってしまうことがある。これを防ぐために、バッチ内のデータについて、各特徴量を正則化する。その後、学習可能なパラメータを用いて、正則化したデータを変換する。これを Batch Normalization（以下、BN）とよぶ。入力が $\mathbf{X} \in \mathbb{M}^{B \times C}$ の行列である場合、正則化を行うのは列ごとであることに注意されたい。

ここでは $\mathbf{X}$ の i 行目ベクトルを $\mathbf{x}^{(i)}$ とする。ここでは、要素 $x_j^{(i)}$ がどのように正則化されるかを考える。その際、 j 列目のことのみを考えればよい。 j 行目の平均を μ_j 、分散を σ_j とし、中間出力を $\mathbf{z}^{(i)}$ 、最終出力を $\mathbf{y}^{(i)}$ とする。すると、BN は以下のように行われる。

$$\begin{aligned}\mu_j &= \frac{1}{B} \sum_{1 \leq k \leq B} x_j^{(k)} \\ \sigma_j^2 &= \frac{1}{B} \sum_{1 \leq k \leq B} \left(x_j^{(k)} - \mu_j \right)^2 \\ z_j^{(i)} &= \frac{x_j^{(i)} - \mu_j}{\sigma_j} \\ y_j^{(i)} &= \gamma_j z_j^{(i)} + \beta_j\end{aligned}$$

ここで、 γ_j と β_j は学習可能なパラメータで、行ごとに別の値が適応される。正則化後のデータを適切にスケールするためのものである。 μ_j 、 σ_j は推論時に列ごとに計算される。つまり、実際には $\gamma, \beta, \mu, \sigma$ はベクトルである。次に、推論時では平均と標準偏差は batch 内のデータを用いて計算されない。なぜなら、推論時には学習時に比べて少ないデータが入力されるからである。したがって、学習時に平均と分散をある程度計算しておく必要がある。毎ステップ、上で計算したバッチの平均と分散を用いて推論時に用いる平均 μ_{running} と分散 $\sigma_{\text{running}}^2$ を更新する。 α は係数である。

$$\begin{aligned}\mu_{\text{running}} &\leftarrow \alpha * \mu_{\text{running}} + (1 - \alpha) \mu \\ \sigma_{\text{running}}^2 &\leftarrow \alpha * \sigma_{\text{running}}^2 + (1 - \alpha) \sigma^2\end{aligned}$$

推論時には μ と σ の代わりに μ_{running} と σ_{running} を用いる。

4.2.1.2. 逆伝播

次に、学習可能なパラメータである γ と β と、 $\mathbf{X}$ の逆伝播を考える。ここでも、 $\frac{\partial \mathcal{L}}{\partial \mathbf{Y}}$ は既知とする。まずは、 $\mathbf{Y}$ から $\mathbf{Z}$ までの逆伝播を考える。まず、 $\gamma_j, \beta_j, z_j^{(i)}$ の損失関数 $\mathcal{L}$ に対する依存関係を整理しよう。

$$\begin{aligned}\gamma_j &\mapsto y_j^{(k)} (1 \leq \forall k \leq B) \mapsto \mathcal{L} \\ \beta_j &\mapsto y_j^{(k)} (1 \leq \forall k \leq B) \mapsto \mathcal{L} \\ z_j^{(i)} &\mapsto y_j^{(i)} \mapsto \mathcal{L}\end{aligned}$$

つまり、

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial z_j^{(i)}} &= \frac{\partial \mathcal{L}}{\partial y_j^{(i)}} \frac{\partial y_j^{(i)}}{\partial z_j^{(i)}} = \frac{\partial \mathcal{L}}{\partial y_j^{(i)}} \gamma_j \\ \frac{\partial \mathcal{L}}{\partial \gamma_j} &= \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial y_j^{(k)}} \frac{\partial y_j^{(k)}}{\partial \gamma_j} \\ &= \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial y_j^{(k)}} z_j^{(k)} \\ \frac{\partial \mathcal{L}}{\partial \beta_j} &= \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial y_j^{(k)}} \frac{\partial y_j^{(k)}}{\partial \beta_j} \\ &= \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial y_j^{(k)}}\end{aligned}$$


である。つまり、ベクトル表現を用いると

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial \gamma} &= \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial \mathbf{y}^{(k)}} \odot \mathbf{z}^{(k)} \\ \frac{\partial \mathcal{L}}{\partial \beta} &= \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial \mathbf{y}^{(k)}}\end{aligned}$$

となる。次に、 $\mathbf{Z}$ から $\mathbf{X}$ までの逆伝播を考える。注意すべき点は $x_j^{(i)}$ が μ や σ に寄与しており、それがすべての $z_j^{(k)} (1 \leq \forall k \leq B)$ に寄与していることである。計算しやすさのため、 $u_j^{(i)} := x_j^{(i)} - \mu_j$ を定義する。すると、 σ_j は

$$\sigma_j = \frac{1}{B} \sum_{1 \leq k \leq B} \left(u_j^{(k)} \right)^2$$

と表される。 $u_j^{(i)}$ を用いて関係をまとめると以下ようになる。ただしこの図で k は $1 \leq k \leq B \wedge k \neq i$ を満たすすべての k である。



$u_j^{(i)}$ に対しては、 $x_j^{(i)}$ が μ_j を介してだけではなく直接作用するので、 $u_j^{(i)}$ と $z_j^{(i)}$ を他の $u_j^{(k)}$ や $z_j^{(k)}$ と区別する必要がある。逆に、 $u_j^{(k)}$ までは区別する必要はないのでこれからは k は i も含めた任意の添字として扱う。まずは、 σ_j について考える。

$$\begin{aligned}
 z_j^{(k)} &= \frac{u_j^{(k)}}{\sigma_j} \Rightarrow \frac{\partial z_j^{(k)}}{\partial \sigma_j} = -\frac{u_j^{(k)}}{\sigma_j^2} \\
 \frac{\partial \sigma_j}{\partial \sigma_j^2} &= \frac{1}{2\sigma_j} \\
 \therefore \frac{\partial \mathcal{L}}{\partial \sigma_j^2} &= \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial z_j^{(k)}} \frac{\partial z_j^{(k)}}{\partial \sigma_j} \frac{\partial \sigma_j}{\partial \sigma_j^2} \\
 &= -\frac{1}{2\sigma_j^3} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial z_j^{(k)}} u_j^{(k)}
 \end{aligned}$$

次に、 $u_j^{(k)}$ について考えると、

$$\sigma_j = \frac{1}{B} \sum_{1 \leq k \leq B} \left(u_j^{(k)}\right)^2 \Rightarrow \frac{\partial \sigma_j^2}{\partial u_j^{(k)}} = \frac{2}{B} u_j^{(k)}$$

である。また、 $z_j^{(k)} = \frac{u_j^{(k)}}{\sigma_j}$ から、 $u_j^{(i)}$ の σ_j に対する依存を一旦無視すると

$$\left. \frac{\partial z_j^{(k)}}{\partial u_j^{(k)}} \right|_{\text{direct}} = \frac{1}{\sigma_j}$$

であるので、

$$\begin{aligned}
 \frac{\partial z_j^{(k)}}{\partial u_j^{(k)}} &= \left. \frac{\partial z_j^{(k)}}{\partial u_j^{(k)}} \right|_{\text{direct}} + \frac{\partial z_j^{(k)}}{\partial \sigma_j^2} \frac{\partial \sigma_j^2}{\partial u_j^{(k)}} \\
 &= \frac{1}{\sigma_j} + \frac{2}{B} u_j^{(k)} \frac{\partial z_j^{(k)}}{\partial \sigma_j^2} \\
 \therefore \frac{\partial \mathcal{L}}{\partial u_j^{(k)}} &= \frac{\partial \mathcal{L}}{\partial z_j^{(k)}} \frac{1}{\sigma_j} + \frac{2}{B} u_j^{(k)} \frac{\partial \mathcal{L}}{\partial \sigma_j^2}
 \end{aligned}$$

となる。最後に $u_j^{(k)}$ に対する $x_j^{(i)}$ への逆伝播を考える。しかし、 μ_j がすべての $u_j^{(k)}$ に寄与していることを考慮する必要がある。

$$\begin{aligned}
 u_j^{(k)} = x_j^{(k)} - \mu_j &\Rightarrow \frac{\partial u_j^{(k)}}{\partial \mu_j} = -1 \\
 \therefore \frac{\partial \mathcal{L}}{\partial \mu_j} &= \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial u_j^{(k)}} \frac{\partial u_j^{(k)}}{\partial \mu_j} \\
 &= - \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial u_j^{(k)}} \\
 &= - \sum_{1 \leq k \leq B} \left[\frac{\partial \mathcal{L}}{\partial z_j^{(k)}} \frac{1}{\sigma_j} + \frac{2}{B} u_j^{(k)} \frac{\partial \mathcal{L}}{\partial \sigma_j^2} \right] \\
 &= - \frac{1}{\sigma_j} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial z_j^{(k)}} - \frac{2}{B} \frac{\partial \mathcal{L}}{\partial \sigma_j^2} \sum_{1 \leq k \leq B} u_j^{(k)}
 \end{aligned}$$

ここで、 $\sum_{1 \leq k \leq B} u_j^{(k)}$ について考えてみる。

$$\begin{aligned}
 \sum_{1 \leq k \leq B} u_j^{(k)} &= \sum_{1 \leq k \leq B} (x_j^{(k)} - \mu_j) \\
 &= \sum_{1 \leq k \leq B} x_j^{(k)} - B\mu_j \\
 &= \sum_{1 \leq k \leq B} x_j^{(k)} - \sum_{1 \leq k \leq B} x_j^{(k)} \\
 &= 0
 \end{aligned}$$

したがって、

$$\frac{\partial \mathcal{L}}{\partial \mu_j} = - \frac{1}{\sigma_j} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial z_j^{(k)}}$$

そして、 $x_j^{(i)}$ は直接 $u_j^{(i)}$ に寄与している他、 μ_j を通して $u_j^{(k)}$ に寄与している。つまり、

$$\begin{aligned}
\mu_j &= \frac{1}{B} \sum_{1 \leq k \leq B} x_j^{(k)} \Rightarrow \frac{\partial \mu_j}{\partial x_j^{(i)}} = \frac{1}{B} \\
\therefore \frac{\partial \mathcal{L}}{\partial x_j^{(i)}} &= \frac{\partial \mathcal{L}}{\partial u_j^{(i)}} \frac{\partial u_j^{(i)}}{\partial x_j^{(i)}} \Bigg|_{\text{direct}} + \frac{\partial \mathcal{L}}{\partial \mu_j} \frac{\partial \mu_j}{\partial x_j^{(i)}} \\
&= \frac{\partial \mathcal{L}}{\partial u_j^{(i)}} + \frac{1}{B} \frac{\partial \mathcal{L}}{\partial \mu_j} \\
&= \frac{\partial \mathcal{L}}{\partial u_j^{(i)}} - \frac{1}{B \sigma_j} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial z_j^{(k)}}
\end{aligned}$$

となる。第1項について詳しく考える。 $z_j^{(k)} = \frac{u_j^{(k)}}{\sigma_j}$ を念頭に考えると、

$$\begin{aligned}
\frac{\partial \mathcal{L}}{\partial u_j^{(i)}} &= \frac{\partial \mathcal{L}}{\partial z_j^{(i)}} \frac{1}{\sigma_j} + \frac{2}{B} u_j^{(i)} \frac{\partial \mathcal{L}}{\partial \sigma_j^2} \\
&= \frac{\partial \mathcal{L}}{\partial z_j^{(i)}} \frac{1}{\sigma_j} + \frac{2}{B} u_j^{(i)} \left(-\frac{1}{2\sigma_j^3} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial z_j^{(k)}} u_j^{(k)} \right) \\
&= \frac{\partial \mathcal{L}}{\partial z_j^{(i)}} \frac{1}{\sigma_j} - \frac{1}{\sigma_j} \frac{1}{B} \frac{u_j^{(i)}}{\sigma_j} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial z_j^{(k)}} \frac{u_j^{(k)}}{\sigma_j} \\
&= \frac{\partial \mathcal{L}}{\partial z_j^{(i)}} \frac{1}{\sigma_j} - \frac{1}{\sigma_j} \frac{z_j^{(i)}}{B} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial z_j^{(k)}} z_j^{(k)}
\end{aligned}$$

つまり、以上をまとめると

$$\begin{aligned}
\frac{\partial \mathcal{L}}{\partial x_j^{(i)}} &= \frac{\partial \mathcal{L}}{\partial z_j^{(i)}} \frac{1}{\sigma_j} - \frac{1}{\sigma_j} \frac{z_j^{(i)}}{B} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial z_j^{(k)}} z_j^{(k)} \\
&= \frac{\partial \mathcal{L}}{\partial z_j^{(i)}} \frac{1}{\sigma_j} - \frac{1}{\sigma_j} \frac{z_j^{(i)}}{B} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial z_j^{(k)}} z_j^{(k)} - \frac{1}{B \sigma_j} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial z_j^{(k)}} \\
&= \frac{1}{\sigma_j} \left[\frac{\partial \mathcal{L}}{\partial z_j^{(i)}} - \frac{z_j^{(i)}}{B} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial z_j^{(k)}} z_j^{(k)} - \frac{1}{B} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial z_j^{(k)}} \right] \\
&= \frac{\gamma_j}{\sigma_j} \left[\frac{\partial \mathcal{L}}{\partial y_j^{(i)}} - \frac{z_j^{(i)}}{B} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial y_j^{(k)}} z_j^{(k)} - \frac{1}{B} \sum_{1 \leq k \leq B} \frac{\partial \mathcal{L}}{\partial y_j^{(k)}} \right]
\end{aligned}$$

となる。最後の等号は、 $\frac{\partial \mathcal{L}}{\partial z_j^{(i)}} = \gamma_j \frac{\partial \mathcal{L}}{\partial y_j^{(i)}}$ を用いている。さて、 γ_j や β_j の勾配を思い出すと、

$$\frac{\partial \mathcal{L}}{\partial x_j^{(i)}} = \frac{\gamma_j}{\sigma_j} \left[\frac{\partial \mathcal{L}}{\partial y_j^{(i)}} - \frac{z_j^{(i)}}{B} \frac{\partial \mathcal{L}}{\partial \gamma_j} - \frac{1}{B} \frac{\partial \mathcal{L}}{\partial \beta_j} \right]$$

となる。この式はすべての j 列に対して成立するのでベクトル表現を用いれば以下のように整理できる。

$$\frac{\partial \mathcal{L}}{\partial \mathbf{x}^{(i)}} = \frac{\gamma}{\sigma} \odot \left[\frac{\partial \mathcal{L}}{\partial \mathbf{y}^{(i)}} - \frac{1}{B} \left\{ \mathbf{z}^{(i)} \odot \frac{\partial \mathcal{L}}{\partial \gamma} + \frac{\partial \mathcal{L}}{\partial \beta} \right\} \right]$$

さらに成分がすべて 1 で大きさ B の列ベクトル $\mathbf{1}_B$ を用いて行列表現に拡張すると以下ようになる。

$$\frac{\partial \mathcal{L}}{\partial \mathbf{X}} = \left(\mathbf{1}_B \cdot \frac{\gamma}{\sigma} \right) \odot \left[\frac{\partial \mathcal{L}}{\partial \mathbf{Y}} - \frac{1}{B} \left\{ \mathbf{Z} \odot \left(\mathbf{1}_B \cdot \frac{\partial \mathcal{L}}{\partial \gamma} \right) + \mathbf{1}_B \cdot \frac{\partial \mathcal{L}}{\partial \beta} \right\} \right]$$

4.2.2. Dropout 層

Dropout は、学習時にランダムにノードを無効化することで、過学習を防ぐ手法である。そもそも背景として、構造の異なる複数のモデルを学習させ、それらの結果を平均化することで、より精度の高いモデルを得るという方法がある。これをアンサンブル学習と呼ぶ。Dropout はミニバッチごとに一定確率でニューロン（ノード）を無効化することで、アンサンブル学習に似た効果を得る手法である。Dropout は、学習時にのみ適応される。推論時はすべてのニューロンを有効化する。また、推論時と同様のスケールに保つため、学習時は Dropout を適応した後にスケールを合わせる必要がある。この Dropout をレイヤとして実装することを考える。

4.2.2.1. 順伝播

全結合層の順伝播でニューロンを無効化するということは、ニューロンの出力を 0 にするということである。無効化を行う層の単一の出力を $\mathbf{y}$ とする。これは Affine 層の出力に関して活性化関数を作用させたものである。もし、 j 番目のニューロンを無効化するならば $y_j = 0$ とするということである。つまり、Dropout 層は Dropout を適応する全結合層の後に適応するように設計するのが適当である。

まず一つのニューロンが無効化される確率を p とする。すると全体で n 個のニューロンがあった時に、 k 個のニューロンが無効化される確率 $P^-(k)$ は

$$P^-(k) = \binom{n}{k} p^k (1-p)^{n-k}$$

である。つまりその期待値は

$$\begin{aligned} E^- &= \sum_{0 \leq k \leq n} k P^-(k) \\ &= \sum_{1 \leq k \leq n} \frac{n!}{(k-1)!(n-k)!} p^k (1-p)^{n-k} \\ &= np \sum_{0 \leq k \leq n-1} \frac{(n-1)!}{k!(n-k-1)!} p^k (1-p)^{n-k-1} \\ &= np(p + (1-p))^{n-1} = np \end{aligned}$$

つまり全体のうち、割合 p だけのニューロンが無効化される。つまり、 $1-p$ の割合のニューロンが有効化される。推論時に比べ、 $1-p$ のスケールが学習時に出力される。これを推論時と同じスケールにするために $1-p$ で割る。また、無効化される成分を 0、そうでない成分を 1 とするベクトル $\mathbf{r}$ を用いる。すると、 $\mathbf{r}$ は p の確率で 0、 $1-p$ の確率で 1 となる。これは $\mathbf{r}$ の各成分がベルヌーイ分布に従うことを意味する。つまり、Dropout 層の順伝播は以下のように表現できる。

$$r_j \sim \text{Bi}(1-p) \quad (1 \leq j \leq n)$$

$$\hat{\mathbf{y}} = \frac{\mathbf{r} \odot \mathbf{y}}{1-p}$$

さて、バッチ学習においてもこれらは基本的に同じである。どのニューロンを無効化するかは、バッチごとではなくデータごとに決定される。つまり、全結合層の出力 $\mathbf{Y} \in \mathbb{M}^{B \times C}$ に対して、Dropout を適応した出力 $\hat{\mathbf{Y}} \in \mathbb{M}^{B \times C}$ は

$$r_{ij} \sim \text{Bi}(1-p) \quad (1 \leq i \leq B, 1 \leq j \leq C)$$

$$\hat{\mathbf{Y}} = \frac{\mathbf{Y} \odot \mathbf{R}}{1-p}$$

で計算される。

4.2.2.2. 逆伝播

Dropout 層には学習可能なパラメータは存在しない。つまり、 $\frac{\partial \mathcal{L}}{\partial \mathbf{Y}}$ のみを考えればいい。

$$\hat{y}_{ij} = \frac{y_{ij} r_{ij}}{1-p}$$

$$\frac{\partial \hat{y}_{ij}}{\partial y_{ij}} = \frac{r_{ij}}{1-p}$$

より、

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial y_{ij}} &= \frac{\partial \mathcal{L}}{\partial \hat{y}_{ij}} \frac{\partial \hat{y}_{ij}}{\partial y_{ij}} \\ &= \frac{\partial \mathcal{L}}{\partial \hat{y}_{ij}} \frac{r_{ij}}{1-p} \\ \therefore \frac{\partial \mathcal{L}}{\partial \mathbf{Y}} &= \frac{1}{1-p} \frac{\partial \mathcal{L}}{\partial \hat{\mathbf{Y}}} \odot \mathbf{R} \end{aligned}$$

となる。

4.3. ペナルティ項の追加

ペナルティ項とは過学習を防ぐために損失関数に追加する項である。過学習の状況ではパラメータが汎用性を失うため、重みといったパラメータが非常に複雑な値をとることがある。これを防ぐために、パ

ラメータの「大きさ」をペナルティとして追加する。パラメータの「大きさ」を求める手法でいくつかの違いが存在する。ここでは、L1 正則化と L2 正則化を紹介する。一方で、実装においては損失関数にペナルティ項を追加するのではなく、Optimizer などの更新時に用いる勾配を変更することで実装することがある。あるペナルティ項を $\mathcal{P}$ とすると、ペナルティ項を追加した損失関数は

$$\mathcal{L}_{\text{new}} = \mathcal{L} + \mathcal{P}$$

である。これを用いてパラメータ p の勾配を考えると、

$$\frac{\partial \mathcal{L}_{\text{new}}}{\partial p} = \frac{\partial \mathcal{L}}{\partial p} + \frac{\partial \mathcal{P}}{\partial p}$$

となる。 $\frac{\partial \mathcal{L}}{\partial p}$ は元の損失関数を用いて今まで通り計算を行った勾配である。つまり、その元の勾配の代わりにそれに $\frac{\partial \mathcal{P}}{\partial p}$ を加えてものを用いることでペナルティ項を追加することができる。

4.3.1. L1 正則化 (Lasso : Least Absolute Shrinkage and Selection Operator)

L1 正則化は、パラメータの「大きさ」として L1 ノルムを用いる手法である。L1 ノルムは、パラメータの絶対値の和である。つまり、新たな損失関数 $\mathcal{L}_{\text{L1}}$ は

$$\mathcal{L}_{\text{L1}} = \mathcal{L} + \lambda \|P\|_1 = \mathcal{L} + \lambda \sum_i |p_i|$$

となる。つまり、新たな勾配との SGD における更新式は

$$\begin{aligned} \frac{\partial \mathcal{L}_{\text{L1}}}{\partial p_i} &= \frac{\partial \mathcal{L}}{\partial p_i} + \lambda \frac{\partial \mathcal{P}}{\partial p_i} \\ &= \frac{\partial \mathcal{L}}{\partial p_i} + \lambda \text{sign}(p_i) \\ p_i &\leftarrow p_i - \eta \frac{\partial \mathcal{L}}{\partial p_i} - \eta \lambda \text{sign}(p_i) \end{aligned}$$

となる。 $\text{sign}(p_i)$ は p_i の符号を表す関数である。つまり、 p_i が正ならば 1、負ならば -1、0 ならば 0 となる。L1 正則化は、比較的強くパラメータを 0 に近づける。なぜなら、パラメータが 0 でなければ、そのスケールに関わらず勾配のペナルティ項の絶対値は 1 である。すると、パラメータが 0 でない限りそれを 0 に近づけようとする力は常に一定で働く。これは結果として、必要最低限のパラメータを取捨選択することにつながり、必要最低限で非常に疎なパラメータを得ることができる。これをスパース性という。

4.3.2. L2 正則化 (Ridge)

L2 正則化は、パラメータの「大きさ」として L2 ノルムを用いる手法である。しかし、諸々の理由で L2 ノルムそのものではなく、その 2 乗を用いる。新たな損失関数 $\mathcal{L}_{\text{L2}}$ は

$$\mathcal{L}_{L2} = \mathcal{L} + \frac{\lambda}{2} \|\mathbf{P}\|_2^2 = \mathcal{L} + \frac{\lambda}{2} \sum_i p_i^2$$

である。ここで、勾配計算の簡単さから $\frac{1}{2}$ を掛けている。つまり、新たな勾配と SGD における更新式は

$$\begin{aligned} \frac{\partial \mathcal{L}_{L2}}{\partial p_i} &= \frac{\partial \mathcal{L}}{\partial p_i} + \lambda p_i \\ p_i &\leftarrow p_i - \eta \frac{\partial \mathcal{L}}{\partial p_i} - \eta \lambda p_i \end{aligned}$$

となる。L2 正則化は、すべてのパラメータを 0 に近づけるように働く。しかし、一方で L1 正則化とは異なり、パラメータを 0 に近づける力はパラメータの大きさに依存しているので、0 に近づけるにつれその力は弱まる。つまり、パラメータはそこまで 0 にはならない。一方で、パラメータが複雑になることを防ぐことができる。

4.3.3. L1L2 正則化 (Elastic Net)

L1L2 正則化は、L1 正則化と L2 正則化を純粹に足し合わせたものである。新たな損失関数 $\mathcal{L}_{L1L2}$ は

$$\mathcal{L}_{L1L2} = \mathcal{L} + \lambda_1 \sum_i |p_i| + \frac{\lambda_2}{2} \sum_i p_i^2$$

となる。つまり、新たな勾配と SGD における更新式は

$$\begin{aligned} \frac{\partial \mathcal{L}_{L1L2}}{\partial p_i} &= \frac{\partial \mathcal{L}}{\partial p_i} + \lambda_1 \text{sign}(p_i) + \lambda_2 p_i \\ p_i &\leftarrow p_i - \eta \frac{\partial \mathcal{L}}{\partial p_i} - \eta \lambda_1 \text{sign}(p_i) - \eta \lambda_2 p_i \end{aligned}$$

となる。

4.3.4. L2 正則化の問題点と AdamW

L2 正則化を Adam と組み合わせて学習を行うと、置き換えたのちの勾配を用いて Adam の更新式を用いることになる。つまり、L2 正則化を行うと、Adam の性質よりそのペナルティ項も含めて更新式を計算することになり、ペナルティ項が Adam でのスケーリングの影響を受けてしまう。これを防ぐために、AdamW という手法が提案された。AdamW は、L2 正則化のペナルティ項を含めない勾配を用いてスケーリングを行ったのち、更新時にペナルティ項を加える手法である。つまり、L2 正則化を Optimizer で担うのである。式は以下のようになる。

$$\begin{aligned}
M &\leftarrow \beta_1 M + (1 - \beta_1) \frac{\partial \mathcal{L}}{\partial P} \\
G &\leftarrow \beta_2 G + (1 - \beta_2) \frac{\partial \mathcal{L}}{\partial P} \odot \frac{\partial \mathcal{L}}{\partial P} \\
\hat{M} &= \frac{M}{1 - \beta_1^{t+1}} \quad \hat{G} = \frac{G}{1 - \beta_2^{t+1}} \\
P &\leftarrow P - \frac{\eta}{\sqrt{\hat{G}}} \hat{M} - \eta \lambda P \\
t &\leftarrow t + 1
\end{aligned}$$

Adam と見比べてみると、 P の更新式にペナルティ 項が追加されていることがわかる。


5. 畳み込みニューラルネットワーク

5.1. 畳み込みへの導入

ここまでのニューラルネットワークでは全結合層をメインに用いてきた。全結合層は、入力のすべての成分が出力のすべての成分に寄与する。入力次元 n のデータに対して、出力次元 m の全結合層を適応する場合、その時間計算量は $O(nm)$ で、空間計算量は $O(nm + m)$ である。これから扱うような画像データのような高次元データに対しては、全結合層は計算量が大きくなりすぎる。そこで、局所受容野と重み共有という工夫を通じて畳み込みという手法を導入する。

5.1.1. 局所受容野

まず、空間的に相関を持つような空間データを考える。これまでの特徴量にはデータ内の位置に意味がないものとして扱っていた。つまり、 x_i と x_{i+1} には隣である意味はなく、全結合層はそれらの空間的位置を無視して関係を学習していた。しかし、画像データが代表するような空間データでは、隣接する特徴量には相関がある。つまり、 x_i と x_{i+1} が隣接していること自体に意味が存在する。そこで、特徴量を局所的に抽出することを考えることができるはずである。空間データの入力ベクトル $\mathbf{x}$ に対して次のようなニューロン結合を考える。



図では少しわかりにくいですが、入力 x_j と x_{j+1} が j 番目のニューロンに結合している。

全結合層では1つのニューロンは入力すべてと結合するが、局所受容野を持つ層では1つのニューロンは入力の一部(=局所受容野)としか結合しない。あるニューロンの出力 y_j は局所受容野からの入力を受け取り、次のニューロンは別の局所受容野をスライドしてそこからの入力を受け取る。局所受容野の幅を f 、局所受容野のスライド幅を s とする。このとき、入力の長さが s の倍数であることは、暗に仮定しよう。上の図では $(f, s) = (2, 1)$ である。すると

$$y_j = \hat{f}(x_{1+s \times (j-1)}, x_{2+s \times (j-1)}, \dots, x_{f+s \times (j-1)})$$

と表せる。つまり、 y_j は局所受容野の $x_{1+s \times (j-1)}$ から $x_{f+s \times (j-1)}$ までの入力で計算される。

5.1.2. 重み共有

局所受容野を用いて限定的なニューロン結合を行い、全結合層と同じ計算を採用すると次のように出力 y_j を計算することになる。なお、活性化関数とバイアスは省略する。

$$y_j = \sum_{1 \leq k \leq f} w_{k+s \times (j-1) \rightarrow j} x_{k+s \times (j-1)}$$

このとき、重み w は単純に $f \times \frac{n}{s}$ だけ準備することになる。さらにパラメータ数を減らすために全ての局所受容野で同じ重みを用いることにする。この重みは局所受容野の重みと呼ばれ、局所受容野から特徴量を正しく抽出するように学習される。つまり、重み共有を行うと、出力 y_j は次のように表せる。

$$y_j = \sum_{1 \leq k \leq f} w_k x_{k+s \times (j-1)}$$

重み共有を行うメリットは、パラメータ数が大幅に減ること以外にもデータの空間的なズレに対してロバストになるということだ。重み共有を行わない層では例えば x_i と x_{i+1} のように少し位置がズレるだけで全く異なる重みを学習することになる。つまり、特徴量の内部表現的な意味はその位置に依存している。しかし、画像のような空間データに関してはそのようなズレを許容しないといけない。画像を少しズラしただけで大きく結果が変わってしまうと困るからである。重み共有をおこなうことで、局所受容野内の特徴量から新たな特徴量を抽出する術のみを学習し、局所受容野内の位置には依存こそすれど、空間データ内の位置には依存しないようにすることができる。局所受容野内および重み共有を採用した上のような計算を畳み込みという。また、畳み込みにおける局所受容野をカーネルあるいはフィルタと呼ぶ。

5.2. テンソルの導入

畳み込みは、1次元のベクトルに対して行うことを考えてきた。しかし、画像データのような3次元のデータに対して畳み込みを行うことを考えたい。そのために、まずテンソルに話を拡張しよう。

そもそも、画像データとは何次元のデータだろうか。全結合層はバッチを考えなければ、1次元データであるベクトルに対して適応されてきた。特徴量一つが一つの成分を表すベクトルである。すると画像は、ピクセルを縦横に並べた2次元のデータだろうか？一般的にはそうではない。画像は、ピクセルを縦横に並べた2次元の構造に加えて、1ピクセルが色の情報をベクトルで持つ。つまり、画像は3次元

のデータである。例えば、RGB 画像は、縦横のピクセルに加えて、色の情報を 3 成分のベクトルで持つ。つまり、画像は画像の横方向、縦方向、そして色方向の 3 次元である。これをテンソルと呼ぶ。テンソルは行列と同様に大きさが存在し、 $a \times b \times c \times \dots$ と表す。一般的に画像は $H \times W \times C$ と表される。 H は高さ、 W は幅、 C はチャンネル数である。RGB 画像は $H \times W \times 3$ で表される。³ グレースケール画像は $H \times W \times 1$ で表される。テンソルは、行列やベクトルを一般化した概念であるが、本書では 3 次元以上のデータをテンソルと呼ぶことにする。 n 次元実数テンソル全体は $\mathbb{R}^{a_1 \times a_2 \times \dots \times a_n}$ である。

また、テンソルは添え字を指定することで行列やベクトルとして扱うこともできる。3 次元テンソル $\mathcal{X} \in \mathbb{R}^{H \times W \times C}$ に対して、

$$\begin{aligned} \mathbf{x}_{ij*} &= (x_{ij1}, x_{ij2}, \dots, x_{ijC}) \in \mathbb{R}^C \\ \mathbf{X}_{i**} &= \begin{pmatrix} x_{i11} & x_{i12} & \dots & x_{i1C} \\ x_{i21} & x_{i22} & \dots & x_{i2C} \\ \vdots & \vdots & \ddots & \vdots \\ x_{iH1} & x_{iH2} & \dots & x_{iHC} \end{pmatrix} \in \mathbb{R}^{H \times C} \end{aligned}$$

となる。特に、 $\mathcal{X}$ はベクトルの行列と同一視できることは重要である。

$$\mathcal{X} = \begin{pmatrix} \mathbf{x}_{11*} & \mathbf{x}_{12*} & \dots & \mathbf{x}_{1C*} \\ \mathbf{x}_{21*} & \mathbf{x}_{22*} & \dots & \mathbf{x}_{2C*} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{x}_{H1*} & \mathbf{x}_{H2*} & \dots & \mathbf{x}_{HC*} \end{pmatrix}$$

5.3. 畳み込み層

では畳み込みをテンソルに対して適応することを考える。まずは、純粹に拡張してみる。テンソル $\mathcal{X} \in \mathbb{R}^{H \times W \times C}$ に対して畳み込みを適応し、出力 $\mathcal{Y} \in \mathbb{R}^{H' \times W' \times C'}$ を得ることを考える。カーネルの大きさ (= カーネルサイズ) を $f_H \times f_W \times f_C$ 、カーネルのスライド幅をそれぞれの軸について s_H, s_W, s_C とする。すると、カーネルの重みは $\mathcal{W} \in \mathbb{R}^{f_H \times f_W \times f_C}$ となる。すると、出力は次のように表せる。

$$y_{i,j,k} = \sum_{1 \leq h \leq f_H} \sum_{1 \leq w \leq f_W} \sum_{1 \leq c \leq f_C} w_{h,w,c} x_{h+s_H \times (i-1), w+s_W \times (j-1), c+s_C \times (k-1)}$$

これで純粹な畳み込みが行える。しかし畳み込みニューラルネットワークで一般的に行われている畳み込みは少し異なる。まず、 H, W 方向と C 方向で扱いが異なる。 C 方向には、1 ピクセルの特徴量が含まれている。つまり、 C 方向については空間データではない。よって、 C 方向については畳み込みを行わないことにする。つまり、

$$f_C = C$$

³チャンネルは色の情報を表すが、チャンネル軸を一番最初の軸として $C \times H \times W$ と表すこともある。本書では $H \times W \times C$ と表す。

とする。また、 s_C は不要である。つまり、 C 方向をベクトルとして扱えることを思い出せば、

$$y_{ij} = \sum_{1 \leq h \leq f_H} \sum_{1 \leq w \leq f_W} w_{hw*} \odot x_{h+s_H \times (i-1), w+s_W \times (j-1), *}$$

と定式化できる。すると、出力の大きさはどうなるだろうか？ここでもストライドはそれぞれの軸について倍数であることを仮定する。すると、出力の大きさは次のように表せる。

$$\begin{aligned} H' &= \frac{H - f_H + 1}{s_H} \\ W' &= \frac{W - f_W + 1}{s_W} \\ C' &= 1 \end{aligned}$$

ここで、 C 方向の大きさが 1 になっていることに着目すると、画像の 1 ピクセルの特徴量が 1 つに圧縮されていることがわかる。しかし、これはあまり望ましくない。なぜなら、1 ピクセルの表現力が失われてしまうからである。また、この計算は H, W 方向については畳み込みを、 C 方向についてはすべての成分に対して異なる重みを用いてその総和を計算していることから 1 ニューロンをもつ全結合層の計算を行っていると解釈できる。つまり、全結合層と同じようにニューロンを増やすことで表現力を増すことができる。そのためには、 C 方向の各成分について異なる重みを準備し、複数回変換を行う必要性がある。よって、異なる C' 個のカーネル $w^{(1)}, w^{(2)}, \dots, w^{(C')}$ を準備し、個々の出力 $y^{(1)}, y^{(2)}, \dots, y^{(C')}$ を得てみよう。

$$y_{i,j}^{(k)} = \sum_{1 \leq h \leq f_H} \sum_{1 \leq w \leq f_W} w_{hw*}^{(k)} \odot x_{h+s_H \times (i-1), w+s_W \times (j-1), *}$$

そして、この個々の出力は C 方向が 1 のテンソルであり、これは 2 次元テンソルつまりは行列として扱える。これを失われた C 方向に結合することで、真の出力 y を得ることができる。

$$\begin{aligned} y &= (y^{(1)}, y^{(2)}, \dots, y^{(C')}) \\ y_{i,j,k} &= \sum_{1 \leq h \leq f_H} \sum_{1 \leq w \leq f_W} w_{hw*}^{(k)} \odot x_{h+s_H \times (i-1), w+s_W \times (j-1), *} \end{aligned}$$

このような計算により、入力テンソル $\mathbb{R}^{H \times W \times C}$ に対して、出力テンソル $\mathbb{R}^{H' \times W' \times C'}$ を得ることができる。 C' は何枚のカーネルを用いるかを与えることになり、モデル設計の段階で決定する。ちょうど、全結合層における出力の次元数を決定するのと同じである。なので、ここで改めて入力チャンネル数 C_{in} と出力チャンネル数 C_{out} を定義する。また、入力 x と重み $w^{(k)}$ のストライド (s_H, s_W) による畳み込みを以下のように表すこととする。

$$y^{(k)} = x *_{(s_H, s_W)} w^{(k)}$$

さらに、バイアスについて考えてみよう。バイアスは、ニューロン1つが1つの値を持ち、入力を重みでスケールさせたのちに加えるスカラーであった。つまり、先ほどの出力 $\mathbf{w}^{(k)}$ の全要素に同一のバイアス b_k を加えればよい。改めてその出力は、

$$\mathbf{x} \in \mathbb{R}^{H \times W \times C_{\text{in}}} : \text{input}$$

$$\mathbf{w} \in \mathbb{R}^{f_H \times f_W \times C_{\text{in}}} : \text{weight}$$

$$\mathbf{y} \in \mathbb{R}^{H' \times W' \times C_{\text{out}}} : \text{output}$$

$$\mathbf{y}^{(k)} = \mathbf{x} *_{(s_H, s_W)} \mathbf{w}^{(k)} + (\mathbf{1}_{H'} \cdot \mathbf{1}_{W'}^\top) b_k \quad k = 1, 2, \dots, C_{\text{out}}$$

$$\mathbf{y} = (\mathbf{y}^{(1)}, \mathbf{y}^{(2)}, \dots, \mathbf{y}^{(C_{\text{out}})})$$

である。これが、畳み込み層の順伝播である。

5.4. パディング

ここまでは畳み込みの際に入力の大きさとストライドの大きさが適切に選ばれている、つまりは正しくストライドが終了することを仮定してきた。しかし、そうではない大きさについても考えたい。まずは、ストライドはできるだけ行われるものとし、必ずカーネルが入力の端にかかるようにしたい。つまり、決めたストライド通りにストライドするが、最後の一回のストライドではカーネルが入力の端にかかるようにする。すると、出力の大きさは次のように表せる。

$$H' = \left\lfloor \frac{H - f_H}{s_H} \right\rfloor + 1$$

$$W' = \left\lfloor \frac{W - f_W}{s_W} \right\rfloor + 1$$

$$C' = C_{\text{out}}$$

当然、このように出力を決めると、出力の大きさが入力と異なる。これ自体は問題にはならないが、出力のサイズが不安定になってしまう。ニューロンの大きさのように狙った大きさにしたいこともある。また、2の累乗や6の倍数といったわかりやすい大きさにすることが望ましい。そのような調整を可能にするため、パディングを導入する。パディングとは、入力の周りに対称になるように0を追加することである。このパディングを行った入力を用いて畳み込みを行うことで、出力の大きさを調整することができる。 H, W 方向のパディングの幅を P_H, P_W とすると、 H, W 軸それぞれ $2P_H, 2P_W$ だけ大きさが増えることになる。つまり、パディングを行った入力の大きさは次のようになる。

$$H' = \left\lfloor \frac{H + 2P_H - f_H}{s_H} \right\rfloor + 1$$

$$W' = \left\lfloor \frac{W + 2P_W - f_W}{s_W} \right\rfloor + 1$$

特に用いられるのがセームパディング (Same Padding) である。セームパディングは、出力の大きさについてフィルタの大きさによるズレを解消するようにパディングをおこなうことである。出力サイズは

$\frac{H}{s_H} \times \frac{W}{s_W}$ となるようにする。 s_H, s_W はそれぞれ H, W を割り切れる値であることは仮定しておく。このような P_H と P_W を計算してみよう。

$$\begin{aligned} \frac{H}{s_H} &= \left\lfloor \frac{H + 2P_H - f_H}{s_H} \right\rfloor + 1 \\ \Leftrightarrow \frac{H}{s_H} - 1 &\leq \frac{H + 2P_H - f_H}{s_H} < \frac{H}{s_H} \\ \Leftrightarrow H - s_H &\leq H + 2P_H - f_H < H \\ \Leftrightarrow f_H - s_H &\leq 2P_H < f_H \\ \Leftrightarrow \frac{f_H - s_H}{2} &\leq P_H < \frac{f_H}{2} \end{aligned}$$

このような条件を満たす P_H ならば Same Padding になるが、ストライドが 1 である場合はこの不等式を満たすような P_H がない場合がある。それは s_H が偶数である場合である。なので、ストライドには奇数を使うことが望ましい。 $s_H > 1$ のときは

$$P_H = \left\lceil \frac{f_H - s_H}{2} \right\rceil$$

を使うことが多い。当然、 P_W についても同様の議論が可能である。いくつかのライブラリでは左右非対称なパディングを行って Same Padding を実装している。が、ここでは議論しないことにする。

5.5. 畳み込みの高速化 (img2col + GM)